



Bericht

Stereo-Rekonstruktion und Stifterkennung

MA-MECH-BB-25

Bildverarbeitung und Machine Learning

Autoren

Matrikelnummern

Supervisor

Kohorte

Lektor

Hannes Unterhuber, Benedikt Reimeir
61901292, 52216064

Ing. Stefan Reinmüller, B.Sc., M.Sc.

MA-MECH-BB-25

Ing. Stefan Reinmüller, B.Sc., M.Sc.

Inhaltsverzeichnis

1	Einleitung	3
1.1	Aufgabenstellung	3
1.2	Projektziele	4
1.3	Abgrenzung	4
2	Theoretische Grundlagen	5
2.1	Bildverarbeitung	5
2.1.1	Kamera, Kalibrierung und Rektifizierung	5
2.1.2	Disparität und 3D-Reprojektion	6
2.1.3	Bildqualität und Artefakte	6
2.2	Machine Learning	6
2.2.1	CNNs und Objektdetektion	6
2.2.2	Transfer Learning und Datenaufbereitung	7
2.3	Trennung der Projektteile	7
3	Durchführung und Umsetzung	8
3.1	Projektstruktur	8
3.2	Teil A: Bildverarbeitung	8
3.2.1	Kalibrierworkflow	8
3.2.2	Aufnahme und Rektifizierung	10
3.2.3	Disparität und Punktwolkenexport	10
3.2.4	Datensanitation	10
3.3	Teil B: Machine Learning	11
3.3.1	Datensatz	11
3.3.2	Training	11
3.3.3	Inferenz im Stereo-Workflow	13
3.4	Zusammenwirken der Module	13
4	Fazit	16
4.1	Zusammenfassung	16
4.2	Grenzen	16
4.3	Ausblick	17
4.4	Verwendete Quellen	17

Kapitel 1

Einleitung

Ziel des Projekts war der Aufbau eines durchgängigen Demonstrators für industrielle Bildverarbeitung und Machine Learning. Der erste Projektteil behandelt die klassische Bildverarbeitung: ein Basler-Stereo-Kamerasystem wird kalibriert, Bildpaare werden rektifiziert, daraus wird eine Disparitätskarte berechnet und anschließend eine farbige 3D-Punktwolke exportiert. Der zweite Projektteil ergänzt diese geometrische Verarbeitung um Machine Learning: ein eigenes YOLO-Modell erkennt Schreibgeräte in den Rohbildern der Kameras.

Die beiden Teile sind bewusst getrennt aufgebaut. Die Bildverarbeitung erzeugt metrische 3D-Informationen und hängt stark von Kamerageometrie, Beleuchtung, Textur und Disparitätsparametern ab. Das Machine-Learning-Modul liefert semantische Information in Form von Klassen, Konfidenzen und Bounding Boxes. Zusammen bilden sie die Grundlage für eine spätere semantische 3D-Auswertung, bei der erkannte Objekte direkt mit Punkten im Raum verknüpft werden könnten.

1.1 Aufgabenstellung

Aus zwei Kamerabildern soll eine verwertbare Punktwolke entstehen. Dafür werden zunächst die intrinsischen Parameter beider Kameras sowie die relative Lage der Kameras zueinander bestimmt. Danach werden neue Stereo-Szenen aufgenommen oder aus dem Projektordner geladen, rektifiziert und mit einem Stereo-Matching-Verfahren verarbeitet. Die Tiefeninformation entsteht aus der Disparität, also der horizontalen Verschiebung korrespondierender Bildpunkte.

Parallel dazu soll ein Detektor für drei Stiftklassen trainiert werden. Die Klassen sind *Fineliner*, *Marker* und *Pencil*. Der Detektor arbeitet auf den unveränderten Rohbildern und ist damit unabhängig von der Rektifizierung und der Punktwolkenberechnung.

1.2 Projektziele

Im Projekt wurden folgende Ziele umgesetzt:

- Mono- und Stereo-Kalibrierung mit einem ChArUco-Board,
- Speicherung wiederverwendbarer Kalibrierparameter,
- Aufnahme und Wiederverwendung von Stereo-Bildpaaren,
- Rektifizierung, Disparitätsschätzung und 3D-Reprojektion,
- Export roher, geschnittener und bereinigter Punktwolken im PLY-Format,
- Integration einer YOLO-Inferenz auf linken und rechten Rohbildern,
- Erstellung und Training eines eigenen YOLO-Datensatzes für Schreibgeräte,
- Dokumentation der erzeugten Artefakte, Grenzen und nächsten Schritte.

1.3 Abgrenzung

Der aktuelle Stand ist ein funktionsfähiger Workflow und keine vollständig validierte Messlösung. Die Punktwolkenqualität wurde visuell und über Plausibilitätswerte geprüft; eine systematische Messunsicherheitsanalyse mit Referenzkörpern wurde noch nicht durchgeführt. Auch die Objekterkennung ist bisher als 2D-Detektor integriert. Eine robuste Fusion von Bounding Boxes und 3D-Punkten ist als nächster Entwicklungsschritt vorgesehen.

Kapitel 2

Theoretische Grundlagen

2.1 Bildverarbeitung

Die Vorlesungsunterlagen zur industriellen Bildaufnahme und Bildverarbeitung behandeln für dieses Projekt besonders relevante Themen: Bildaufnahme, Bildqualität, geometrische Transformationen, Kamerakalibrierung und 3D-Rekonstruktion. Genau diese Bausteine bilden den klassischen Bildverarbeitungsteil des Projekts.

2.1.1 Kamera, Kalibrierung und Rektifizierung

Eine reale Kamera bildet die Welt nicht ideal pinhole-artig ab. Brennweite, Hauptpunkt und Verzeichnung müssen deshalb modelliert werden. Diese Parameter werden als intrinsische Parameter bezeichnet. Bei einem Stereo-System kommt zusätzlich die extrinsische Beziehung zwischen linker und rechter Kamera hinzu, also Rotation und Translation zwischen den beiden Kamerakoordinatensystemen.

Im Projekt wird ein ChArUco-Board verwendet. ChArUco kombiniert ArUco-Marker mit Schachbrettecken. Dadurch können Kalibrierpunkte auch dann eindeutig erkannt werden, wenn nicht das gesamte Board sichtbar ist. Das eingesetzte Board besitzt 11×8 Quadrate, eine Quadratgröße von 10 mm und eine Markergröße von 7 mm. Da diese Geometrie in Millimetern angegeben ist, werden auch die rekonstruierten 3D-Punkte in Millimetern interpretiert.

Nach der Kalibrierung werden Stereo-Bildpaare rektifiziert. Die Rektifizierung transformiert beide Bilder so, dass korrespondierende Bildpunkte auf derselben Bildzeile liegen. Dadurch wird aus einer zweidimensionalen Suche nach passenden Bildpunkten eine eindimensionale Suche entlang horizontaler Epipolarlinien.

2.1.2 Disparität und 3D-Reprojektion

Die Disparität beschreibt die horizontale Verschiebung eines Objektpunktes zwischen linkem und rechtem Bild. Nahe Objekte erzeugen größere Disparitäten als weit entfernte Objekte. Im Projekt wird Semi-Global Block Matching eingesetzt. Das Verfahren vergleicht lokale Bildbereiche, berücksichtigt aber zusätzlich Glattheitsannahmen, damit die berechnete Disparitätskarte weniger sprunghaft wird.

Gültige Disparitätswerte werden anschließend mit der von OpenCV erzeugten Reprojektionsmatrix Q in 3D-Punkte umgerechnet. Die Farbinformation wird aus dem rektifizierten linken Kamerabild übernommen. Ergebnis ist eine farbige Punktwolke, die als PLY-Datei gespeichert und mit Open3D, MeshLab oder CloudCompare betrachtet werden kann.

2.1.3 Bildqualität und Artefakte

Stereo-Matching ist empfindlich gegenüber schwacher Textur, Überbelichtung, Bewegungsunschärfe, spiegelnden Oberflächen und ungeeigneten Disparitätsgrenzen. Deshalb enthält der Workflow Kontrastverbesserung durch CLAHE, eine automatische Warnung bei Disparitätssättigung und nachgelagerte Filter für Tiefenbereich, Disparitätsbereich und zusammenhängende Komponenten.

2.2 Machine Learning

Die Vorlesungsunterlagen zu Machine Learning in der industriellen Bildverarbeitung behandeln unter anderem überwachte Lernverfahren, Datenmanagement, Convolutional Neural Networks, Transfer Learning, Datenaufbereitung und typische Herausforderungen. Für dieses Projekt sind vor allem CNNs, Transfer Learning, Datenlabeling und Augmentation relevant.

2.2.1 CNNs und Objektdetektion

Convolutional Neural Networks sind für Bilddaten geeignet, weil Faltungsfiler lokale Muster wie Kanten, Ecken, Texturen und Objektteile über das gesamte Bild wiederverwenden. Durch Parameter Sharing und lokale Rezeptivfelder können CNNs Bildmerkmale effizient lernen. Bei der Objektdetektion wird nicht nur eine Klasse für das gesamte Bild vorhergesagt, sondern es werden zusätzlich Bounding Boxes für einzelne Objekte bestimmt.

YOLO-Modelle formulieren Objektdetektion als schnellen Vorwärtsdurchlauf eines neuronalen Netzes. Die Ausgabe besteht aus Klasse, Konfidenz und Bounding Box. Im Projekt wird YOLO als semantisches Modul eingesetzt: Es erkennt Schreibgeräte in den Rohbildern, während die Stereo-Pipeline die geometrische 3D-Information erzeugt.

2.2.2 Transfer Learning und Datenaufbereitung

Das Training moderner Detektionsnetze von Grund auf benötigt große Datenmengen und viel Rechenleistung. Deshalb wurde ein vortrainiertes YOLO11m-Modell verwendet und auf den eigenen Stiftdatensatz angepasst. Das entspricht dem Transfer-Learning-Gedanken: allgemeine Bildmerkmale werden aus einem vortrainierten Modell übernommen, während das Modell auf die projektspezifischen Klassen feinangepasst wird.

Für überwachte Detektion ist die Labelqualität entscheidend. Die Projektbilder wurden in Bounding-Box-Form annotiert und in Trainings-, Validierungs- und Testdaten aufgeteilt. Augmentationen wie Skalierung, Translation, horizontales Spiegeln, Farbanpassungen, Mosaic und Random Erasing erhöhen die Robustheit gegenüber realen Aufnahmevariationen.

2.3 Trennung der Projektteile

Die Bildverarbeitung arbeitet deterministisch mit expliziten Kameramodellen und geometrischen Annahmen. Ihre Ergebnisse sind metrisch interpretierbar, aber empfindlich gegen Kalibrier- und Matchingfehler. Das Machine-Learning-Modul arbeitet datengetrieben. Es liefert semantische Entscheidungen, deren Qualität von Datensatz, Labeling und Generalisierung abhängt. Im Projekt sind beide Module getrennt lauffähig und werden erst auf Ebene der Anwendung zusammengeführt.

Kapitel 3

Durchführung und Umsetzung

3.1 Projektstruktur

Die Umsetzung ist als Python-Projekt mit PDM organisiert. Die wichtigsten Dateien und Ordner sind:

- `calib/mono_then_stereo_calibration.ipynb`: Mono- und Stereo-Kalibrierung,
- `scene_pointcloud_from_stereo.ipynb`: Aufnahme, Detektion, Rektifizierung, Disparität, Punktwolkenexport und Sanitation,
- `calib/mono_camera_params.pkl`: gespeicherte Mono-Intrinsiken,
- `calib/stereo_params_mono_first.pkl`: gespeicherte Stereo-Parameter,
- `captures/`: gespeicherte linke und rechte Stereo-Rohbilder,
- `detections/`: YOLO-Ausgaben auf Rohbildern,
- `pointclouds/`: exportierte PLY-Punktwolken,
- `CustomModel/TrainingData/Stifterkennung.yolov11/`: YOLO-Datensatz,
- `best.pt`: Trainingsergebnisse.

Die wesentlichen Bibliotheken sind OpenCV, pypylon, Open3D, NumPy, Matplotlib und Ultralytics YOLO. Der Quellcode ist notebookbasiert, damit Kalibrierung, Sichtprüfung und Export schrittweise nachvollzogen werden können.

3.2 Teil A: Bildverarbeitung

3.2.1 Kalibrierworkflow

Die Kalibrierung folgt einem Mono-First-Ansatz. Zuerst wurden linke und rechte Kamera separat kalibriert. Danach wurde die Stereo-Beziehung mit fixierten Mono-Intrinsiken bestimmt. Diese Tren-

nung erleichtert die Fehlersuche, weil schlechte Einzelkameraparameter nicht erst in der Stereo-Kalibrierung sichtbar werden.

Die Konfiguration des Kalibriernotebooks umfasst ein ChArUco-Board mit 11×8 Quadraten, 10 mm Quadratgröße, 7 mm Markergröße, DICT_4X4_50 und aktivierter Legacy-ChArUco-Anordnung. Für gültige Bilder werden mindestens zwölf interpolierte ChArUco-Ecken gefordert. Kameraordnung, Beleuchtung, Gain, Fokus, Auflösung und Boardgeometrie müssen während einer Kalibriersitzung unverändert bleiben.

Tabelle 3.1: Wesentliche Kalibrierparameter des aktuellen Stands.

Parameter	Wert
Bildgröße	1280×1024 px
Mono-RMS links/rechts	ca. 0,23 px / 0,24 px
Stereo-RMS	ca. 1,34 px
Baseline	ca. 123 mm
Kalibriereinheit	Millimeter
Ausgabedatei	calib/stereo_params_mono_first.pkl

Die gespeicherten Stereo-Parameter enthalten die Kameramatrizen, Verzeichnungskoeffizienten, Rotation, Translation, Essential- und Fundamental-Matrix, Rektifizierungsmatrizen, Projektionsmatrizen und die Reprojektionsmatrix Q .




Abbildung 3.1: Aufbau der Stereo-Kamera mit ChArUco-Board zur Kalibrierung.

3.2.2 Aufnahme und Rektifizierung

Das Rekonstruktionsnotebook kann entweder neue Bilder mit den Basler-Kameras aufnehmen oder das neueste gespeicherte Stereo-Paar aus `captures/` verwenden. Im Workspace liegen 60 Szenen- und Testbilder, also 30 linke/rechte Paare, vor. Vor dem Stereo-Matching kann CLAHE aktiviert werden, um lokale Kontraste zu erhöhen.



Abbildung 3.2: Beispiel eines gespeicherten Stereo-Rohbildpaars aus dem Ordner `captures/`.

Die Rektifizierung wird mit den gespeicherten OpenCV-Parametern durchgeführt. Dadurch liegen korrespondierende Punkte idealerweise auf gleicher Bildhöhe. Dieser Schritt ist die Voraussetzung dafür, dass StereoSGBM sinnvoll arbeiten kann.

3.2.3 Disparität und Punktwolkenexport

Für die Disparitätsberechnung wird `cv2.StereoSGBM_create` eingesetzt. Die aktuelle Konfiguration nutzt `minDisparity = 0`, `initial numDisparities = 384`, maximal 512, eine Blockgröße von 7, `uniquenessRatio = 8`, `speckleWindowSize = 80`, `speckleRange = 2` und den Modus `STEREO_SGBM_MODE_SGBM_3WAY`. Wenn mehr als fünf Prozent der gültigen Pixel am oberen Disparitätslimit liegen, erweitert das Notebook den Disparitätsbereich automatisch.

Nach der Disparitätsschätzung werden nur Punkte im Tiefenbereich von 400 mm bis 650 mm übernommen. Die Punktwolken werden als PLY-Dateien gespeichert. Um sehr große Dateien handhabbar zu halten, wird beim Speichern auf maximal 400 000 Punkte reduziert.

3.2.4 Datensanitation

Zusätzlich zur rohen Punktwolke erzeugt das Notebook bereinigte Varianten. Der erste Bereinigungs-schritt schneidet die Disparitätskarte anhand definierter Disparitäts- und Bildbereichsgrenzen. Der

Tabelle 3.2: Erzeugte Bildverarbeitungsartefakte im Workspace.

Artefakt	Anzahl / Zweck
<code>captures/</code>	60 Rohbilder
<code>detections/</code>	26 annotierte YOLO-Bilder
<code>pointclouds/</code>	21 PLY-Punktwolken
<code>calib/*.pkl</code>	gespeicherte Kalibrierparameter

zweite Schritt arbeitet auf der gültigen Disparitätsmaske und behält den größten zusammenhängenden Bereich. Kleine getrennte Komponenten werden ab einer Mindestfläche von 2 000 Pixeln gefiltert.

Beim letzten dokumentierten Lauf wurden nach der Disparitäts- und Tiefenfilterung 278 810 Kandidatenpunkte betrachtet. Die Sanitation behielt 268 574 Punkte, also 96,33 Prozent. Der resultierende Bereich lag bei etwa $X = -77,1$ bis $197,3$ mm und $Z = 523,9$ bis $580,7$ mm. Die bereinigte Datei `scene_pointcloud_sanitized_20260616_091546.ply` hat eine Größe von ca. 3,84 MB.

3.3 Teil B: Machine Learning

3.3.1 Datensatz

Für die Stifterkennung wurde ein eigener YOLO-Datensatz erstellt. Die Ausgangsbilder liegen zusätzlich nach Klassen sortiert in `CustomModel/TrainingData/`: 50 Bilder für *Marker*, 50 für *Fineliner*, 50 für *Pencil* und 60 gemischte Bilder. Der daraus exportierte Roboflow/YOLO-Datensatz enthält drei Klassen:

- Klasse 0: *Fineliner*,
- Klasse 1: *Marker*,
- Klasse 2: *Pencil*.

Die Aufteilung im YOLO-Datensatz besteht aus 144 Trainingsbildern, 41 Validierungsbildern und 21 Testbildern. Die Labels liegen im YOLO-Format als normalisierte Bounding Boxes vor.

3.3.2 Training

Trainiert wurde mit Ultralytics YOLO11m. Als Startpunkt wurde ein vortrainiertes Modell verwendet. Die Trainingskonfiguration nutzte 640 Pixel Eingabegröße, Batchgröße 8, Validierung während des Trainings, deterministische Ausführung mit Seed 0 und automatische Optimizer-Auswahl. Die Trainingskonfiguration war auf 300 Epochen mit Patience 50 ausgelegt; der gespeicherte Lauf umfasst 129 Epochen.




Abbildung 3.3: Label- und Bounding-Box-Verteilung des YOLO-Trainingsdatensatzes.

Zur Regularisierung und besseren Generalisierung wurden Standard-Augmentationen verwendet: HSV-Anpassung, Translation, Skalierung, horizontales Spiegeln, Mosaic, RandAugment und Random Erasing. Diese Augmentationen passen zur Empfehlung, kleine industrielle Bilddatensätze künstlich zu variieren, damit das Modell nicht nur die konkreten Trainingsaufnahmen auswendig lernt.

Tabelle 3.3: YOLO-Trainingsergebnisse des Laufs `stiftererkennung_yolo11m`.

Metrik	Bester Wert	Epoche
Precision	0,996	117
Recall	0,967	129
mAP@50	0,985	128
mAP@50:95	0,845	79




Abbildung 3.4: Trainingsverlauf mit Verlusten und Validierungsmetriken des YOLO11m-Modells.

3.3.3 Inferenz im Stereo-Workflow

Die YOLO-Inferenz wurde in das Rekonstruktionsnotebook integriert, bleibt aber von der Punktwolkenberechnung getrennt. Das Modell wird aus `best.pt` geladen, die Konfidenzschwelle beträgt 0,4 und die IoU-Schwelle 0,45. Die Erkennung wird auf linkes und rechtes Rohbild angewendet. Die Ausgaben werden mit Bounding Boxes gespeichert.

3.4 Zusammenwirken der Module

Der aktuelle Workflow nutzt YOLO zur semantischen Analyse der Rohbilder und StereoSGBM zur geometrischen Rekonstruktion. Diese Reihenfolge ist praktisch, weil die Objekterkennung nicht durch




Abbildung 3.5: Normalisierte Confusion Matrix des trainierten YOLO-Modells.



Abbildung 3.6: YOLO-Inferenz auf linken und rechten Rohbildern vor der Rektifizierung.

Rektifizierungsartefakte beeinflusst wird. Für eine spätere 3D-Objektauswertung könnten die 2D-Bounding-Boxes auf die rektifizierten Bilder übertragen und anschließend mit den gültigen 3D-Punkten innerhalb der jeweiligen Objektregion verknüpft werden.

Kapitel 4

Fazit

4.1 Zusammenfassung

Im Projekt wurde ein vollständiger Workflow für Stereo-Bildverarbeitung und Machine-Learning-basierte Objekterkennung umgesetzt. Der Bildverarbeitungsteil umfasst die ChArUco-basierte Mono- und Stereo-Kalibrierung, die Speicherung der Kalibrierparameter, die Aufnahme und Wiederverwendung von Stereo-Bildpaaren, die Rektifizierung, die Berechnung von Disparitätskarten mit StereoSGBM und den Export farbiger Punktwolken. Ergänzend wurden Filter zur Entfernung unplausibler Tiefen, Disparitätsartefakte und kleiner getrennter Komponenten erstellt.

Der Machine-Learning-Teil umfasst einen eigenen YOLO-Datensatz für drei Schreibgeräteklassen und ein trainiertes YOLO11m-Modell. Der beste Trainingsstand erreicht eine mAP@50 von 0,985 und eine mAP@50:95 von 0,845. Die Inferenz wurde in das Rekonstruktionsnotebook integriert und erzeugt annotierte linke und rechte Rohbilder.

Wichtig ist die klare Rollenverteilung: Die klassische Bildverarbeitung liefert metrische 3D-Geometrie, das Machine Learning liefert semantische Objektinformation. Beide Teile sind getrennt nachvollziehbar und bilden gemeinsam eine solide Basis für semantische 3D-Szenenanalyse.

4.2 Grenzen

Die Punktwolkenqualität hängt stark von der Kalibrierung, der Szene, der Beleuchtung und dem Disparitätsbereich ab. Schwach texturierte oder spiegelnde Oberflächen können weiterhin zu Fehlmatches führen. Der Stereo-RMS-Wert von ca. 1,34 px ist als Plausibilitätswert brauchbar, zeigt aber auch, dass eine genauere Kalibrierkampagne die 3D-Qualität verbessern könnte.

Beim YOLO-Modell ist die Validierungsleistung hoch, der Datensatz ist jedoch klein und aus ähnlichen Aufnahmebedingungen entstanden. Deshalb sollte die gute mAP nicht als Garantie für beliebige neue Szenen verstanden werden. Besonders andere Hintergründe, Beleuchtungen, Verdeckungen und Kamerawinkel sollten für eine robuste Bewertung zusätzlich getestet werden.

4.3 Ausblick

Die nächsten sinnvollen Schritte sind:

- quantitative Bewertung der 3D-Rekonstruktion mit Referenzobjekten,
- zusätzliche Kalibrierbilder mit stärkerer Abdeckung des Bildfeldes,
- systematische Parameterstudie für StereoSGBM,
- Erweiterung des YOLO-Datensatzes um mehr Hintergründe, Abstände und Verdeckungen,
- Auswertung des Testsets zusätzlich zur Validierung,
- Fusion von 2D-Bounding-Boxes mit den rekonstruierten 3D-Punkten,
- Berechnung objektbezogener 3D-Merkmale wie Schwerpunkt, Ausdehnung und Abstand.

4.4 Verwendete Quellen

Als fachliche Grundlage wurden zuerst die bereitgestellten Kursunterlagen verdichtet und auf das Projekt bezogen:

- Stefan Reinmüller: *Industrielle Bildaufnahme & Bildverarbeitung*, veröffentlicht am 13.04.2026, <https://stefan-reinmueller.github.io/MECH-M-DUAL-2-BEV/>.
- Peter Kandolf: *Machine Learning in Industrial Image Processing*, veröffentlicht am 04.04.2026, <https://kandolfp.github.io/MECH-M-DUAL-2-MLB/>.

Zusätzlich wurden die Projektdateien, Notebooks, gespeicherten Kalibrierparameter, YOLO-Konfigurationen, Trainingsmetriken und erzeugten Artefakte im Workspace als direkte Quellen für die Dokumentation verwendet.